

Oftalmologie-Detectia lichidului macular

1st Bulgaru Vlad-Andrei
1307B

2nd Cobzariu Stefan-Alexutu
1307B

Abstract—Solutia acestui proiect se concentreaza spre detectarea lichidului macular, punand accentul pe degenerescenta maculara legata de varsta (AMD), folosind retele neuronale secventiale pentru a realiza o clasificare cu o acuratete si precizie cat mai mare, utilizand librariile Keras si TensorFlow in limbajul Python.

I. INTRODUCERE

Degenerescenta maculara legata de varsta (AMD) este o cauza majora a orbirii la nivel mondial. Odata cu imbatranirea populatiei in multe tari, mai mult de 20 la suta ar putea avea aceasta tulburare. Detectarea lichidului macular devine o preocupare vitala in medicina oculara, cu un accent deosebit pe degenerescenta maculara legata de varsta (AMD). Lichidul macular, acumulat in zona centrala a retinei, poate indica evolutia bolilor oculare si necesita o interventie medicala prompta.

II. DESCRIEREA METODEI

In acest proiect, noi ne-am propus sa realizam o clasificare de imagini care foloseste un model de invatare automata compus din retele neuronale secventiale, antrenate cu un set de date de antrenament compus din 1800 de imagini, toate la aceeasi dimensiune si un set de imagini de validare, compus din 400 de imagini, ambele seturi cuprinzand un numar de 2 clase: ochi afectat de degenerescenta maculara legata de varsta (AMD) si ochi normal. In prima etapa a proiectului, are loc incarcarea setului de date si impartirea in subseturi, dupa care are loc antrenarea retelei neuronale. Modelul este antrenat pe mai multe epoch-uri, in numar de 60, oferindu-ne detalii despre parametri - acuratete si pierdere. Intrucat nu am reusit sa obtinem imagini noi pentru ochiul afectat de amd, ci doar pentru ochiul sanatos, am modificat numarul imaginilor cu AMD din setul initial de antrenament si validare (cel de la etapa preliminara) pentru a ne crea un set de imagini de testare. Testarea se face utilizand o imagine extrasa random din setul de date de testare ce contine imagini noi neetichetate (care nu au fost folosite la antrenarea modelului). Modelul realizeaza clasificarea, extragand caracteristicile relevante din imagini, avand ca output ponderile ce apartin celor doua clase si ulterior sunt convertite de functia de activare softmax in probabilitati. Am antrenat un model secvential custom, care


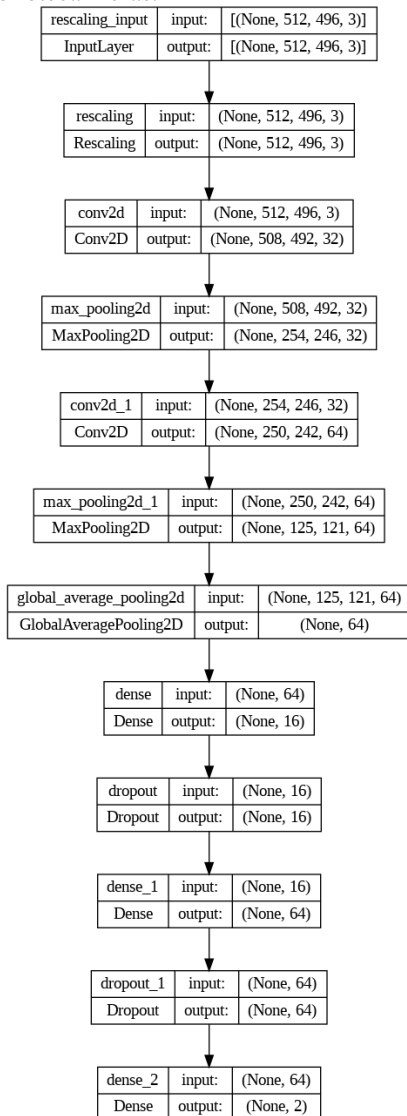


Fig. 1. Imagini din setul de date

permite adaugarea straturilor intr-o maniera liniara, una dupa alta. Fiecare strat are exact o intrare si o iesire. Modelul nostru secvential este alcatuit din 12 layere(straturi), respectiv: Primul strat (de input) Rescaling: acest strat a fost utilizat pentru redimensionarea valorilor pixelilor imaginilor la intervalul [0,1]. Aceasta redimensionare asigura ca datele de intrare sunt intr-un interval mai mic, facilitand astfel antrenarea retelei. Mai contine 2 straturi de Conv2D: acesta reprezinta un strat de convolutie bidimensional care aplica un numar de filtre pe imaginea de intrare de dimensiunea parametrului kernel-size pentru a detecta diferite caracteristici esentiale in realizarea procesului de invatare a modelului pe setul de date. Doua straturi MaxPooling2D: este un strat care efectueaza esantionarea, selectand valoarea maxima din fiecare regiune a imaginii. Are rolul de a reduce dimensiunea imaginii pentru a scade complexitatea modelului. Un strat GlobalAveragePooling2D: acest strat are rolul de a calcula rezultatul mediu al fiecarui filtru de trasaturi din stratul anterior. Trei straturi Dense: acest

strat este unul complet conectat in care fiecare neuron din strat este conectat la fiecare neuron din stratul anterior si fiecare neuron din stratul urmator, realizand conectarea completa intre straturi, avand ca obiectiv aducerea caracteristicilor in punctul in care se face prezicerea. Doua straturi Dropout: acest strat dezactiveaza aleatoriu un numar de neuroni din stratul anterior, astfel incat de fiecare data neuronii diferiti afecteaza neuronii din stratul urmator, pentru a realiza o generalizare mai buna. In final, solutia noastra realizeaza clasificarea intre o poza cu un ochi normal si una in care ochiul este afectat de degenerescenta maculara prin preluarea de trasaturi extrase din imaginile continute in setul de date. Proiectul este realizat in Google Colab, in limbajul Python, utilizand platforma open-source pentru invatare automata TensorFlow, utilizand biblioteca Keras.



III. REZULTATE PRELIMINARE

Acestea sunt rezultatele preliminare ale proiectului.

Nu sunt niste rezultate foarte bune in prima faza, dar ne propunem sa le imbunatatim considerabil.

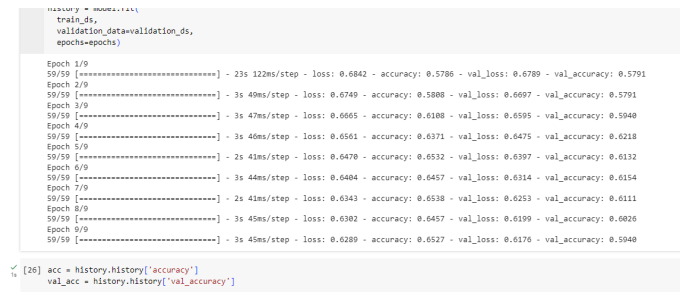


Fig. 2. Rezultate preliminare




Fig. 3. Graficul cu rezultatele preliminare

IV. CONCLUZII PRELIMINARE

In concluzie, rezultatele nu sunt cele asteptate, dar ne dorim sa avem pe viitor o imbunatatire a parametrilor, reprezentati de pierdere si acuratete, pentru a atinge o rata apropiata de valoarea de 90 la suta.


V. REZULTATE FINALE

Acestea sunt rezultatele finale ale proiectului.

In comparatie cu rezultatele obtinute in etapa intermediara, am obtinut o imbunatatire a parametrilor, atingand o performanta apropiata de 90 la suta acuratete.

De asemenea, modelul nostru este capabil sa realizeze o predictie a imaginilor din setul de test, avand o rata de incredere apropiata de 70 la suta.

Fig. 4. Rezulate finale



Metoda prezentata in acest articol se concentreaza pe generarea de imagini medicale sintetice, in special imagini ale fundusului ocular, utilizand retelele neuronale GAN (Generative Adversarial Networks). Aceasta solutie este propusa pentru a aborda limitarile seturilor de date medicale, care sunt insuficient etichetate pentru antrenarea si validarea modelelor de invatare profunda. Performanta este evaluata utilizand

Acest articol se refera la utilizarea rețelelor neuronale convoluționale adanci (Deep Convolutional Neural Networks -

DCNNs), in special a caracteristicilor pre-antrenate dintr-o retea numita OverFeat, pentru detectarea degenerarii maculare legate de varsta (AMD). Pentru a aborda problema selectiei caracteristicilor, acestia au luat in considerare functiile OverFeat (OF) care rezulta dintr-un model preluat DCNN ce a fost antrenat in prealabil pe setul de date ImageNet constand din peste un milion de imagini ImageNet de uz general (non-medical) cu o mie de clase de imagini constand din animale, obiecte comestibile, obiecte uzuale de uz casnic, etc. Ei au utilizat caracteristicile de retea pre-antrenate OF DCNN si au ajustat parametrii retelei pentru imaginile preprocesate ale fundului retinian. Lucrarea evalueaza eficacitatea retelei neuronale convolutionale profunde (DCNN) drept metoda potentiala pentru detectarea si clasificarea AMD. Atunci cand se aplica clasificari ale imaginilor, o diferenta importanta intre DCNN si metodele conventionale de invatare automata este procesul de selectie a caracteristicilor. In special, inainte de clasificare, metodele conventionale includ o etapa in care sunt calculate caracteristici vizuale specifice. Aceasta selectie manuala (sau design de caracteristici) poate avea ca rezultat un set de caracteristici care este prea specializat pentru un anumit set de date, ceea ce duce la o aplicabilitate reduasa la un set mai mare sau seturi de date necunoscute. In schimb, functiile DCNN nu sunt proiectate manual, ci sunt gasite in timpul antrenamentului si optimizarii cu ponderi in retea. Cu toate acestea, aceasta optimizare necesita un numar substantial de imagini (sute de mii sau milioane) pentru a invata in mod fiabil ponderile (milioane de parametri), iar setul acestora de date (AREDS) este format din doar cateva mii de imagini. S-au folosit imagini color fundus din baza de date AREDS pentru a caracteriza performanta algoritmului DCNN, iar performanta algoritmului DCNN este evaluata folosind metrici precum sensibilitate si valoare predictiva pozitiva.

E. Automated Age-Related Macular Degeneration and Diabetic Macular Edema Detection on OCT Images using Deep Learning[Sertan Kaymak, Ali Serener]

Acest articol vorbeste despre detectarea automata a DME si AMD folosind metode de invatare profunda are mai multe avantaje. Unul dintre avantajele cheie este ca boala poate fi detectata in stadiile incipiente. Cu un algoritm de invatare profund conceput cu atentie, simptomele mici pot fi detectate cu acuratete chiar si atunci cand sunt neobservate de un oftalmolog in timpul unui control. Prin urmare, medicul oftalmolog poate incepe tratamentul aferent inainte de evolutia bolii. Metoda folosita se bazeaza pe antrenarea unui algoritm de invatare profunda pentru a le clasifica in categoriile AMD sanatoase, uscate, AMD umede si DME. Aceasta metoda foloseste o arhitectura numita AlexNet care depaseste o metoda bazata pe transfer de invatare propusa recent in literatura de specialitate pentru clasificarea imaginilor OCT in categoriile AMD si DME. Setul lor de date contine 83484 imagini OCT care antreneaza modelul. Aceste imagini RGB au rezolutii diferite si sunt toate redimensionate la $256 \times 256 \times 3$. Performanta de clasificare este evaluata pentru categoriile de imagini. Acestea constau din 26315 imagini sanatoase, 8616 imagini AMD

uscate, 37205 imagini AMD umede si 11348 imagini DME. Performanta este testata folosind 250 de imagini din fiecare categorie. Acuratetea modelului AlexNet este de 97,1 la suta, sensibilitatea este de 99,6 la suta iar specificitatea este de 98,4 la suta. Arhitectura originala AlexNet este utilizata in timpul antrenamentului. Cadrul de invatare profunda AlexNet este antrenat folosind un singur GPU NVIDIA GeForce GTX 1080Ti, generarea modelului realizandu-se folosind 800 de epoci.

F. Related Work

Solutiile comerciale existente pe piata sunt:

VeriSee AMD este un software de screening asistat de AI pentru degenerescenta maculara legata de varsta (AMD) care identifica pacientii cu AMD cu risc ridicat.

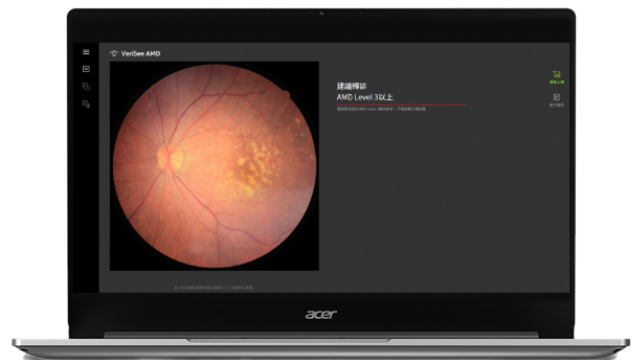


Fig. 7. VeriSee AMD

eyecare- Amsler Grid Eye Test este o aplicatie conceputa pentru monitorizarea personala a pierderii vederii din cauza degenerescentei maculare.

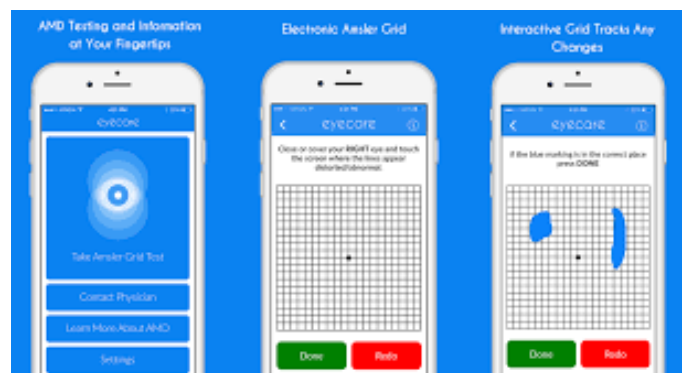


Fig. 8. Amsler Grid Eye Test

REFERENCES

- [1] Which Generative Adversarial Network Yields High-Quality Synthetic Medical Images: Investigation Using AMD Image Datasets[Guilherme C. Oliveira, Gustavo H. Rosaa, Daniel C. G. Pedronettea, João P. Papaa, Himeesh Kumarc, Leandro A. Passosd, Dinesh Kumar]

- [2] Machine learning based detection of age-related macular degeneration (AMD) and diabetic macular edema (DME) from optical coherence tomography (OCT) images[Yu Wang, Yaonan Zhang, Fengfeng Zhou, Ruixue Zhao, Zhaomin Yao]
- [3] Multi-scale convolutional neural network for automated AMD classification using retinal OCT images[Saman Sotoudeh-Paima, Ata Jodeiri, Fedra Hajizadeh, Hamid Soltanian-Zadeh]
- [4] Detection of age-related macular degeneration via deep learning [P. Burlina, D. E. Freund, N. Joshi, Y. Wolfson, N. M. Bressler]
- [5] Automated Age-Related Macular Degeneration and Diabetic Macular Edema Detection on OCT Images using Deep Learning[Sertan Kaymak, Ali Serener]