

Oftalmologie-Detectia lichidului macular

1st Bulgaru Vlad-Andrei
1307B

2nd Cobzariu Stefan-Alexutu
1307B

Abstract—Solutia acestui proiect se concentreaza spre detectarea lichidului macular, punand accentul pe degenerescenta maculara legata de varsta (AMD), folosind retele neuronale secventiale pentru a realiza o clasificare cu o acuratete si precizie cat mai mare, utilizand librariile Keras si TensorFlow in limbajul Python.

I. INTRODUCERE

Degenerescenta maculara legata de varsta(AMD) este o cauza majora a orbirii la nivel mondial. Odata cu imbatranirea populatiei in multe tari, mai mult de 20 la suta ar putea avea aceasta tulburare. Detectarea lichidului macular devine o preocupare vitala in medicina oculara, cu un accent deosebit pe degenerescenta maculara legata de varsta(AMD). Lichidul macular, acumulat in zona centrala a retinei, poate indica evolutia bolilor oculare si necesita o interventie medicala prompta.

II. DESCRIEREA METODEI

In acest proiect, noi ne propunem sa realizam o clasificare care foloseste retele neuronale antrenate cu un set de date compus din 2200 de imagini, toate la aceeasi dimensiune, si impartite in seturi de antrenament si seturi de validare, cuprinzand 2 clase: amd si normal. In prima faza a proiectului, are loc incarcarea setului de date si impartirea in subseturi, dupa are loc antrenarea retelei neuronale Modelul este antrenat pe mai multe epoch-uri, oferindu-ne detalii despre parametri - acuratete si pierdere. In final, solutia noastra ar trebui sa aiba capacitatea de a face distinctia pe baza unui set nou de date intre o poza cu un ochi normal si una in care ochiul este afectat de degenerescenta maculara. Proiectul va fi realizat in Google Colab, in limbajul Python, utilizand bibliotecile Keras si TensorFlow.

III. REZULTATE PRELIMINARE

Acestea sunt rezultatele preliminare ale proiectului.

Nu sunt niste rezultate foarte bune in prima faza, dar ne propunem sa le imbunatatim considerabil.

IV. CONCLUZII PRELIMINARE

In concluzie, rezultatele nu sunt cele asteptate, dar ne dorim sa avem pe viitor o imbunatatire a parametrilor, reprezentati de pierdere si acuratete, pentru a atinge o rata apropiata de valoarea de 90 la suta.

Identify applicable funding agency here. If none, delete this.

```
history = model.fit(
    train_ds,
    validation_data=validation_ds,
    epochs=epochs)

Epoch 1/9 [=====] - 23s 122ms/step - loss: 0.6842 - accuracy: 0.5786 - val_loss: 0.6789 - val_accuracy: 0.5791
Epoch 2/9 [=====] - 3s 40ms/step - loss: 0.6749 - accuracy: 0.5888 - val_loss: 0.6697 - val_accuracy: 0.5791
Epoch 3/9 [=====] - 3s 47ms/step - loss: 0.6665 - accuracy: 0.6108 - val_loss: 0.6595 - val_accuracy: 0.5940
Epoch 4/9 [=====] - 3s 40ms/step - loss: 0.6561 - accuracy: 0.6371 - val_loss: 0.6475 - val_accuracy: 0.6218
Epoch 5/9 [=====] - 2s 41ms/step - loss: 0.6470 - accuracy: 0.6532 - val_loss: 0.6397 - val_accuracy: 0.6132
Epoch 6/9 [=====] - 3s 44ms/step - loss: 0.6404 - accuracy: 0.6457 - val_loss: 0.6314 - val_accuracy: 0.6154
Epoch 7/9 [=====] - 2s 41ms/step - loss: 0.6343 - accuracy: 0.6538 - val_loss: 0.6253 - val_accuracy: 0.6111
Epoch 8/9 [=====] - 3s 45ms/step - loss: 0.6302 - accuracy: 0.6457 - val_loss: 0.6199 - val_accuracy: 0.6026
Epoch 9/9 [=====] - 3s 45ms/step - loss: 0.6289 - accuracy: 0.6527 - val_loss: 0.6176 - val_accuracy: 0.5940

acc = history.history['accuracy']
val_acc = history.history['val_accuracy']
```

Fig. 1. Rezultate preliminare




Fig. 2. Graficul cu rezultatele preliminare

V. STATE OF THE ART SI RELATED WORK

A. Which Generative Adversarial Network Yields High-Quality Synthetic Medical Images: Investigation Using AMD Image Datasets[Guilherme C. Oliveira, Gustavo H. Rosaa, Daniel C. G. Pedronettea, João P. Papaa, Himeesh Kumar, Leandro A. Passosd, Dinesh Kumar]

Metoda prezentata in acest articol se concentreaza pe generarea de imagini medicale sintetice, in special imagini ale

fundusului ocular, utilizand retelele neuronale GAN (Generative Adversarial Networks). Aceasta solutie este propusa pentru a aborda limitările seturilor de date medicale, care sunt insuficient etichetate pentru antrenarea și validarea modelelor de învățare profundă. Performanța este evaluată utilizând metrici precum FID, clasificare cu ajutorul experților clinici și clasificare prin deep learning

B. Machine learning based detection of age-related macular degeneration (AMD) and diabetic macular edema (DME) from optical coherence tomography (OCT) images[Yu Wang, Yaonan Zhang, Fengfeng Zhou, Ruixue Zhao, Zhaomin Yao]

Metoda propusă în acest articol se referă la dezvoltarea unui model de diagnostic asistat de calculator (CAD) pentru discriminarea între AMD, edemul macular diabetic (DME) și o maculă sanatoasă pe baza imaginilor de tomografie de coerență optică (OCT). Autorii au folosit în cadrul acestei metode caracteristici bazate pe AlexNet, care este o rețea neuronală convoluțională. Scopul acestei abordări este să ofere o modalitate de diagnostic automatizat, care să poată identifica aceste afecțiuni oculare prin analiza imaginilor OCT. Rezultatele obținute arată că modelul propus atinge o acuratețe globală de 99,3 la sută în clasificarea între AMD, DME și o maculă sanatoasă, depășind performanțele modelelor existente.

C. Multi-scale convolutional neural network for automated AMD classification using retinal OCT images[Saman Sotoudeh-Paima, Ata Jodeiri, Fedra Hajizadeh, Hamid Soltanian-Zadeh]

În acest articol se introduce o metodă bazată pe o rețea neuronală convoluțională multi-scală cu structura Feature Pyramid Network (FPN). Evaluarea se face pe un set de date național de la spital (NEH) și pe setul de date public UCSD, iar rezultatele experimentale arată performanța superioară a structurii multi-scală propuse față de alte cadre cunoscute de clasificarea OCT. Asadar, metoda propusă depășește performanța altor cadre, oferind o soluție end-to-end eficientă.

D. Detection of age-related macular degeneration via deep learning [P. Burlina, D. E. Freund, N. Joshi, Y. Wolfson, N. M. Bressler]

Acest articol se referă la utilizarea rețelelor neuronale convoluționale avansate (Deep Convolutional Neural Networks - DCNNs), în special a caracteristicilor pre-antrenate dintr-o rețea numită OverFeat, pentru detectarea degenerării maculare legate de vârstă (AMD). S-au folosit imagini color fundus din baza de date AREDS pentru a caracteriza performanța algoritmului DCNN, iar performanța algoritmului DCNN este evaluată folosind metrici precum sensibilitate și valoare predictivă pozitivă.

E. Automated Age-Related Macular Degeneration and Diabetic Macular Edema Detection on OCT Images using Deep Learning[Sertan Kaymak, Ali Serener]

Metoda folosită se bazează pe antrenarea unui algoritm de învățare profundă pentru a le clasifica în categoriile AMD

sanatoase, uscate, AMD umede și DME. Aceasta metodă folosește o arhitectură numită AlexNet care depășește o metodă bazată pe transfer de învățare propusă recent în literatură de specialitate pentru clasificarea imaginilor OCT în categoriile AMD și DME. Setul lor de date conține 83484 imagini OCT care antrenează modelul. Aceste imagini RGB au rezoluții diferite și sunt toate redimensionate la 256×256×3. Performanța de clasificare este evaluată pentru categoriile de imagini. Acestea constau din 26315 imagini sanatoase, 8616 imagini AMD uscate, 37205 imagini AMD umede și 11348 imagini DME. Performanța este testată folosind 250 de imagini din fiecare categorie. Acuratetea modelului AlexNet este de 97,1

F. Related Work

Soluțiile comerciale existente pe piață sunt:

VeriSee AMD este un software de screening asistat de AI pentru degenerescența maculară legată de vârstă (AMD) care identifică pacienții cu AMD cu risc ridicat.

eyecare- Amsler Grid Eye Test este o aplicație concepută pentru monitorizarea personală a pierderii vederii din cauza degenerescenței maculare.

REFERENCES

- [1] Which Generative Adversarial Network Yields High-Quality Synthetic Medical Images: Investigation Using AMD Image Datasets [Guilherme C. Oliveira, Gustavo H. Rosaa, Daniel C. G. Pedronettea, João P. Papaa, Himeesh Kumarc, Leandro A. Passosd, Dinesh Kumar]
- [2] Machine learning based detection of age-related macular degeneration (AMD) and diabetic macular edema (DME) from optical coherence tomography (OCT) images [Yu Wang, Yaonan Zhang, Fengfeng Zhou, Ruixue Zhao, Zhaomin Yao]
- [3] Multi-scale convolutional neural network for automated AMD classification using retinal OCT images [Saman Sotoudeh-Paima, Ata Jodeiri, Fedra Hajizadeh, Hamid Soltanian-Zadeh]
- [4] Detection of age-related macular degeneration via deep learning [P. Burlina, D. E. Freund, N. Joshi, Y. Wolfson, N. M. Bressler]
- [5] Automated Age-Related Macular Degeneration and Diabetic Macular Edema Detection on OCT Images using Deep Learning [Sertan Kaymak, Ali Serener]